

Business Intelligence e Gestão Baseada em Dados

Trabalho Prático

Áthila Archanji Rodrigues
Diogo Delazare Brandão
Guilherme Augusto Barbosa Amorim
Heitor Pinheiro Sousa

- Objetivo do projeto

Analisar o comportamento do fundo Banestes Infra EV ESG FII e seu impacto na operação de uma rede de eletropostos no Espírito Santo.

- Fontes de dados internas e externas (recorte/imagem)

A nossa fonte primária e verdadeira (externa) é a frota de veículos do SENATRAN, distribuída por tipo de combustível utilizado, estado e município de origem. A partir dela, nós calculamos a frota recarregável de automóveis pelo estado do ES, para podermos gerar dados condizentes com a realidade.

A imagem abaixo ilustra um recorte da base de dados do SENATRAN.

UF	Município	Combustível Veículo	Qtd. Veículos
SAO PAULO	SAO PAULO	GASOLINA	4330375
SAO PAULO	SAO PAULO	ALCOOL/GASOLINA	4289276
MINAS GERAIS	BELO HORIZONTE	ALCOOL/GASOLINA	1905010
Sem Informação	Sem Informação	GASOLINA	1479671
DISTRITO FEDERAL	BRASILIA	ALCOOL/GASOLINA	1264772
RIO DE JANEIRO	RIO DE JANEIRO	ALCOOL/GASOLINA	1175433
RIO DE JANEIRO	RIO DE JANEIRO	GASOLINA	1108547
PARANA	CURITIBA	ALCOOL/GASOLINA	960019

Recorte da base de dados do SENATRAN

Primeiro, criamos o fundo e alguns cotistas, de perfis diferentes de investimento, e estabelecemos um valor inicial da cota. Depois, usando a fonte externa, criamos dados de projetos de instalação de eletropostos e das recargas feitas neles pelos usuários do eletroposto durante o período de 1 ano. Tendo em vista que a frota recarregável do estado é de 8 mil veículos, simulamos 220 mil cargas, o que equivale a cerca de 2 cargas ao mês por veículo, para equilibrar entre os usuários hipotéticos esporádicos (raramente carregam nos eletropostos) e os recorrentes (como motoristas de aplicativo, que carregam até 10 vezes por mês).

As imagens abaixo mostram recortes de cada uma das bases de dados geradas:

id_cotista	perfil_risco	municipio_origem	uf	data_entrada	valor_investido
2824	Arrojado	AFONSO CLAUDIO	ESPIRITO SANTO	2024-08-03	30229.25
5506	Moderado	GUARAPARI	ESPIRITO SANTO	2025-01-21	10425.48
4657	Moderado	MARECHAL FLORIANO	ESPIRITO SANTO	2024-10-31	41434.63
2679	Moderado	SANTA MARIA DE JETIBA	ESPIRITO SANTO	2025-12-22	61322.43

Recorte da base de dados sobre cotistas

id_fundo	nome_fundo	taxa_administracao	benchmark	data_inicio
1	Banestes Infra EV ESG FII	0.015	IPCA + 6%	2023-01-01

Base de dados sobre o fundo de investimento

id_projeto	municipio	uf	tipo_local	capex	opex_mensal	qtd_carregadores	potencia_instalada_kw	status	data_inicio_operacao	frota_eletrica_municipio_ref
1	CARIACICA	ESPIRITO SANTO	Shopping	444095.27	6011.66	7	150	Em Operação	2024-10-27	1379
2	SERRA	ESPIRITO SANTO	Supermercado	451907.51	6095.5	8	150	Em Operação	2026-05-10	870
3	CARIACICA	ESPIRITO SANTO	Estacionamento Privado	335935.77	4771.02	5	150	Em Operação	2026-02-06	1379
4	NOVA VENECIA	ESPIRITO SANTO	Rodovia	226152.16	3617.12	3	100	Em Operação	2024-09-21	30

Recorte de base de dados sobre projetos de eletropostos (primeiras colunas)

frota_hibrida_plugin_municipio_ref	frota_recarregavel_municipio_ref	participacao	frota_es_pct	indice_demanda_senatran	classe_demanda_senatran	demandas_mensal_estimada_recargas	fonte_demanda
66	1445		17.7148	89.01	MUITO ALTA	160	SENATRAN
177	1047		12.8356	75.76	MUITO ALTA	193	SENATRAN
66	1445		17.7148	89.01	MUITO ALTA	120	SENATRAN
24	54		0.662	17.21	MEDIA	41	SENATRAN

Recorte de base de dados sobre projetos de eletropostos (últimas colunas)

id_fundo	data_referencia	aporte_liquido_mes
1	2023-01-31	123758.87
1	2023-02-28	102194.16
1	2023-03-31	150520.03
1	2023-04-30	99470.55


Recorte da base de dados sobre movimentações do fundo de investimento

id_operacao	id_projeto	data_hora	municipio_origem_veiculo	uf_origem_veiculo	tipo_veiculo_recarregavel	veiculo_modelo	energia_consumida_kwh	tempo_utilizacao_min	preco_kwh_br	receita_gerada_br
ed3049cd-43e4-48fc-a3f2-ae24fc3d3348		1 2026-07-12 21:24:24	ANCHIETA	ESPIRITO SANTO	ELETRICO	BYD Seal	51.16	52	2	102.3
490617b2-747b-4d8a-889e-3ccdc8b8d9c9		1 2025-09-18 16:37:21	BAIXO GUANDU	ESPIRITO SANTO	ELETRICO	Nissan Leaf	26.22	35	2	52.4
bb026576-f512-44c3-b253-d2186c4a37#		1 2025-09-27 15:41:09	CARIACICA	ESPIRITO SANTO	ELETRICO	Volvo EX30	47.02	47	2.3	108.1
a97065e1-8e46-4534-888a-618efed405#		1 2026-06-13 09:21:54	CARIACICA	ESPIRITO SANTO	ELETRICO	Volvo EX30	40.56	44	2.3	93.2

Recorte da base de dados sobre recargas

A base de dados do SENATRAN foi obtida como um arquivo csv diretamente do site do SENATRAN. Os dados da taxa selic foram obtidos dinamicamente através da API do Banco Central do Brasil.

A imagem abaixo ilustra os arquivos de dados “crus” presentes na camada bronze da data warehouse:



Lista de arquivos de dados na camada bronze

- Dicionário de dados das fontes de dados interna e externa utilizadas

O dicionário de dados pode ser encontrado na raiz do repositório do projeto, no arquivo DICIONARIO_DE_DADOS.md, disponível publicamente em: <https://github.com/AthilaArchanji/projeto-bi-banestes-ev/>.

- Questões de análise

1. Quais municípios possuem maior frota recarregável?
2. Quais municípios possuem mais projetos?
3. Quais municípios possuem mais veículos por projeto ou por carregador?
4. Quais projetos geraram maior receita?
5. Quais projetos apresentaram maior margem bruta?
6. Como a quantidade de recargas evoluiu ao longo do tempo?
7. Em quais horários ocorre a maior demanda por recargas?
8. Quais projetos forneceram mais energia?
9. Como a rentabilidade do fundo evoluiu em comparação com a Selic?
10. Como os cotistas estão distribuídos por município e perfil de risco?
11. Em quais períodos o fundo superou a Selic e qual foi o retorno excedente?

- Modelo dimensional

O modelo dimensional dos dados pode ser encontrado na raiz do repositório do projeto, no arquivo MODELO_DIMENSIONAL.md, disponível publicamente em: <https://github.com/AthilaArchanji/projeto-bi-banestes-ev/>.

- Ferramentas utilizadas

O processo de geração de dados fictícios, aquisição de dados da taxa selic, análise e agregação dos dados foi feito usando a linguagem Python e a biblioteca Pandas.

Para a geração de alguns dos dados fictícios, foi utilizada a biblioteca Faker.

A ferramenta Data Studio foi utilizada para montagem do dashboard.

- Pipeline de dados (processo)

Inicialmente a base de dados do SENATRAN foi baixada em formato xlsx do site oficial do SENATRAN. Baseado nessa base de dados, um script python cria arquivos csv das demais bases de dados utilizadas no projeto e também salva dados históricos da taxa selic adquiridos via API do BCB, culminando no estado da camada bronze da data warehouse.

Um segundo script python é responsável por ler todos os arquivos da camada bronze e fazer a limpeza dos mesmos, padronizando nomes de colunas, nomes de cidades e estados, convertendo campos de colunas para seus devidos tipos de dados, retirando valores duplicados, nulos ou inválidos e salvando novos arquivos com esses dados tratados na camada silver.

um terceiro e último script python é responsável por fazer os devidos processamentos e agregações dos dados presentes na camada silver para fornecer as métricas e visualizações pertinentes às perguntas propostas, e salvar esses dados processados na camada gold.

Por fim, esses dados são importados para o Data Studio para a criação do dashboard interativo que permite a fácil visualização das métricas relevantes para responder às perguntas propostas.

- Processo de ingestão da fonte de dados, tratamento e carga do data warehouse (passo-a-passo e scripts).

A camada Bronze, implementada no arquivo 01_ingestao_bronze.py, usa numpy para gerar valores aleatórios, pandas para estruturar as tabelas, requests para buscar a Selic na API do Banco Central e Faker para criar identificadores e datas simuladas. O pipeline separa os dados em pastas próprias para Bronze, Silver e Gold e começa carregando a base bruta da SENATRAN, que é normalizada apenas para servir de referência à simulação, sem sobrescrever a fonte original em Excel. A partir dessa base, ele filtra os registros do Espírito Santo e mantém apenas veículos recarregáveis, consolidando a frota elétrica e híbrida plug-in por município. Em seguida, gera um índice de demanda municipal com base na participação da frota local em relação ao maior município, aplicando raiz quadrada para reduzir a distância entre cidades maiores e menores.

Na geração dos projetos de eletropostos, o pipeline cria 30 projetos, garantindo presença em pelo menos 12 municípios com maior frota recarregável e distribuindo os demais com peso crescente para municípios com maior demanda. Os tipos de

local são escolhidos de forma aleatória, mas ponderada: para municípios com maior índice de demanda, prevalecem perfis urbanos como Shopping, Supermercado, Estacionamento Privado, Posto de Combustível e Rodovia, enquanto em municípios com menor demanda os perfis rodoviários ganham mais peso. Cada projeto recebe status de "Em Operação" ou "Em Construção", quantidade de carregadores, potência instalada, custo de construção proporcional, custo de operação mensal estimado e demanda mensal estimada de recargas.

A geração dos cotistas também é orientada pela demanda real da frota, concentrando mais cotistas nos municípios com maior presença de veículos recarregáveis. O pipeline cria três perfis de risco, Conservador, Moderado e Arrojado, com distribuição ponderada de 20%, 50% e 30%, respectivamente, e associa cada perfil a faixas diferentes de valor investido. Já as movimentações do fundo são criadas como aportes mensais brutos, preservando apenas o fato de entrada de capital na Bronze, sem calcular rentabilidade, cota ou patrimônio nessa etapa.

Na geração das operações de recarga, o pipeline simula 220 mil recargas, considerando apenas projetos ativos, equivalente a uma média de 1 recarga a cada 2 semanas por veículo recarregável no Estado. A distribuição das recargas é ponderada pela frota recarregável do município, pela quantidade de carregadores e pela concentração de projetos no município, de modo que cidades com mais veículos elétricos e mais estações recebem maior volume de operações. As sessões são distribuídas por hora com pesos que concentram maior movimento no meio da manhã e no fim da tarde, a origem do veículo é majoritariamente local, e o tipo do veículo define a carga em kWh e a potência efetiva usada no cálculo do tempo. O preço por kWh parte de uma base de 1,50 e é ajustado de acordo com a potência instalada do projeto. Por fim, a Selic é obtida da fonte externa do Banco Central e salva em sua forma bruta para tratamento posterior na camada Silver.

A camada Silver, implementada no arquivo `02_tratamento_silver.py`, faz a limpeza, padronização e validação das bases da Bronze antes de qualquer análise. O primeiro passo é normalizar textos para remover acentos, espaços duplicados e padronizar tudo em maiúsculas, além de converter ES e variações para ESPIRITO SANTO, garantindo compatibilidade entre as fontes. O pipeline também valida a existência das colunas obrigatórias em cada tabela, evitando que erros de estrutura avancem para etapas posteriores.

No tratamento da base da SENATRAN, o processo renomeia colunas, normaliza textos, converte a quantidade de veículos para numérico e filtra apenas os registros do Espírito Santo e apenas os veículos recarregáveis. Com isso, a base Silver deriva uma frota consolidada por município, separando frota elétrica e híbrida

plug-in, calculando a frota recarregável total, a participação da frota no estado, o índice de demanda do município e sua classificação em MUITO ALTA, ALTA, MÉDIA, BAIXA ou SEM FROTA RECARREGÁVEL. Esse índice é o mesmo princípio usado na Bronze para orientar a simulação dos projetos e depois na Gold para priorização de investimento.

No tratamento da dimensão do fundo, o pipeline remove duplicidades, padroniza os campos textuais, converte `data_inicio` para `DateTime`, transforma `taxa_administracao` em numérico e descarta registros inválidos. Nos projetos, ele elimina duplicidades, normaliza município e status, converte a data de início da operação para `DateTime`, converte as colunas numéricas e filtra apenas projetos do Espírito Santo, com município válido na base da SENATRAN, custo de construção positivo, custo de operação positivo e pelo menos um carregador. Além disso, compara a frota de referência armazenada na simulação com a frota atual do SENATRAN e registra a diferença, criando um controle de consistência da premissa usada na geração dos dados.

Na base de cotistas, a Silver remove duplicidades, padroniza município e UF, converte `data_entrada` para `DateTime`, transforma `valor_investido` em numérico e mantém apenas linhas válidas do Espírito Santo, com município existente no SENATRAN e valores positivos. Na base de movimentações do fundo, o tratamento faz a mesma lógica de limpeza: remove duplicadas, converte `data_referencia` para `DateTime`, transforma `aporte_liquido_mes` em numérico e elimina linhas inválidas, preservando somente os aportes brutos.

O pipeline de base de operações de recarga remove duplicidades, converte `data_hora` para `DateTime`, normaliza texto, padroniza a UF, converte as colunas numéricas para tipo numérico e mantém apenas registros válidos, com projeto existente, data válida, município de origem válido, UF do Espírito Santo, tipo de veículo recarregável permitido e consumo e receita positivos. Depois disso, ele adiciona a localização do eletroposto com base no projeto, deriva `data_referencia`, `ano_mes`, `hora_recarga` e `dia_semana`, cria a flag de `origem_local` comparando município de origem e município do eletroposto, calcula `custo_energia_brl` assumindo custo médio de 90 centavos por kWh e calcula `margem_bruta_brl` como receita menos custo de energia.

Por fim, a base da Selic também é tratada na Silver: o pipeline normaliza os campos, converte data para `DateTime`, converte valor para numérico substituindo vírgula por ponto, renomeia os campos para `data_referencia` e `taxa_selic_mes`, filtra a série a partir de janeiro de 2024 e descarta valores inválidos. Em paralelo, o processo grava um controle de qualidade com o número de registros de entrada, saída e removidos em cada tabela, o que documenta formalmente a transformação aplicada em toda a camada.

A camada gold, implementada no arquivo 03_geracao_gold.py se divide em diferentes camadas, focadas em calcular diferentes métricas pertinentes às perguntas elaboradas.

A etapa de criação de análise de viabilidade por município combina a frota recarregável da base da SENATRAN com os projetos implantados e com o histórico de operações de recarga. A partir disso, o pipeline agrega por município os principais sinais de oferta e demanda: quantidade total de projetos, quantidade de projetos em construção, quantidade de projetos em operação, custo de construção total, custo de operação mensal total, quantidade de carregadores, potência instalada total e demanda mensal estimada de recargas. Na camada de operações, consolida quantidade de recargas, meses com operação, energia total recarregada, receita total, margem bruta total e recargas originadas de veículos do mesmo município do eletroposto. Com essas bases, calcula razões como veículos por projeto, veículos por carregador, média mensal de recargas, recargas por 100 veículos, receita por veículo, percentual de recargas de origem local e percentual de atingimento da demanda esperada. Em seguida, deriva o índice de déficit de infraestrutura, que penaliza municípios com muita frota e poucos carregadores, gera scores percentuais para frota, déficit e demanda observada, e combina esses três componentes no índice de oportunidade de investimento com pesos de 45%, 35% e 20%, respectivamente. A partir desse índice, o pipeline também classifica a existência de projetos, define prioridade de expansão e recomendações de investimento, gerando a saída final em gold_oportunidade_municipios.csv.

A etapa de desempenho consolidado dos projetos parte das operações de recarga agrupadas por projeto e consolida o comportamento econômico e operacional de cada unidade. O pipeline soma quantidade de recargas, energia total fornecida, tempo total de utilização, receita total, custo total de energia, margem bruta total, ticket médio, energia média por recarga, tempo médio de recarga, meses com operação e recargas de origem local. Depois, junta essas medidas à dimensão de projetos e complementa a análise com métricas derivadas: margem bruta percentual, receita por carregador, média mensal de recargas, atingimento da demanda estimada, percentual de recargas de origem local, custo de operação do período, margem de lucro após o custo de operação e retorno operacional sobre o custo de construção. É gerado um rótulo legível do projeto, ordenado por receita total e exportado em gold_desempenho_projetos.csv. Essa etapa responde às perguntas sobre quais projetos geram mais receita, mais margem e mais energia..

A etapa de evolução mensal das recargas organiza todas as operações por mês e produz uma visão temporal do uso da rede. O pipeline consolida quantidade de recargas, projetos com movimento, municípios com movimento, energia total, receita total, custo total de energia, margem bruta total e ticket médio por mês. Em seguida, cria a coluna data_mes para facilitar séries temporais e calcula a margem bruta percentual mensal. O resultado é salvo em gold_operacoes_mensais.csv,

servindo de base para a leitura da evolução do volume de recargas ao longo do tempo.

A etapa de demanda por horário agrupa as operações pelo horário de recarga e mede como a demanda se distribui ao longo do dia. O pipeline soma quantidade de recargas, energia total, receita total e tempo médio de recarga por hora, além de criar uma faixa horária formatada no padrão HH:00. A tabela final é ordenada do menor para o maior horário e exportada em `gold_demanda_horaria.csv`. Essa saída responde diretamente à pergunta sobre quais horários concentram maior demanda.

A etapa de origem municipal da demanda identifica de quais municípios partem os veículos que utilizam os eletropostos. O pipeline agrupa as operações pelo município, consolidando quantidade de recargas originadas, energia total e receita associada. Depois, faz o merge com a frota recarregável do município de origem e calcula a participação percentual dessas recargas no total e a métrica de recargas por 100 veículos. A base final é ordenada pela quantidade de recargas originadas e exportada como `gold_origem_recargas_municipios.csv`.

A etapa de distribuição dos cotistas usa a dimensão de cotistas para entender como o capital está distribuído geograficamente e por perfil de risco. O pipeline agrupa os cotistas por UF, município de origem e perfil de risco, consolidando quantidade de cotistas, valor total investido e investimento médio. Em seguida, calcula a participação dos cotistas no total e a participação do investimento no total, ordena o resultado pelo valor investido e grava a saída em `gold_cotistas_municipio_perfil.csv`. Essa tabela responde à pergunta sobre distribuição dos cotistas por município e perfil.

A etapa de rentabilidade consolidada do fundo e comparação com a Selic cruza a movimentação do fundo, a série histórica da Selic e a dimensão do fundo, normaliza datas e cria uma janela mensal para análise. A partir daí, consolida por mês os projetos em operação e calcula o lucro mensal dos projetos ativos, considerando receita, custo de energia, margem bruta, custo de operação e lucro operacional por projeto. O pipeline assume apenas projetos em operação com data de início válida e considera que o custo operacional incide desde o início da operação, mesmo em meses sem recarga, para evitar superestimação do lucro. Com essa base, calcula a rentabilidade mensal do fundo usando o lucro operacional dos projetos, a taxa administrativa mensal equivalente, o capital base do mês anterior e os aportes líquidos do período. Em seguida, gera o valor da cota, o patrimônio líquido e a rentabilidade mensal em percentual. Depois, faz o merge com a Selic mensal e calcula retorno excedente percentual, indicador de superação da Selic, retorno do fundo em reais, retorno equivalente da Selic em reais e retorno excedente em reais. A etapa fecha com os acumulados de rentabilidade do fundo, Selic acumulada, retorno excedente acumulado em pontos percentuais e em reais, meses acima da Selic acumulados e percentual acumulado de meses acima da Selic. Essa parte


exporta gold_lucro_projetos_mensal.csv, gold_rentabilidade_fundo.csv, gold_desempenho_fundo_selic.csv e gold_resumo_fundo_selic.csv.


A etapa de resumo executivo geral consolida os principais indicadores para consumo em cartões e painéis gerenciais. O pipeline reúne quantidade de cotistas, valor total investido, quantidade total de projetos, projetos em operação, custo de construção total, quantidade total de recargas, energia total fornecida, receita total de recargas, margem bruta total e frota recarregável do Espírito Santo. Também calcula a correlação entre frota recarregável e recargas por município e usa o município com maior índice de oportunidade como destaque do resumo. O resultado final é exportado em gold_resumo_executivo.csv.

Os scripts estão disponíveis publicamente no repositório <https://github.com/AthilaArchanji/projeto-bi-banestes-ev/>. No mesmo repositório também estão disponíveis instruções de como executar o pipeline de processamento de dados e um vídeo demonstrando a execução.


- Dashboard (imagem)

O dashboard do projeto foi feito na plataforma Data Studio e pode ser acessado em: <https://datastudio.google.com/reporting/ba74a398-ae95-4e6b-a3b0-61166c1d54d7>.





Distribuição dos projetos por município



Meses Totais Analisados

30

Rentabilidade Selic Acum.

35,45%

Rentabilidade Fundo Acum.

28,61%

Meses Rentabilidade>Selic

11

Retorno Excedente Total

R\$ 82.019,76